

Método de sobre-relajación sucesiva (SOR)

Deducción desde la formulación matricial, por coordenadas y su relación con Gauss–Seidel

Universidad de Pamplona – Facultad de Ciencias Básicas

1. Planteamiento del problema y descomposición de la matriz

Se desea resolver el sistema lineal

$$A\mathbf{x} = \mathbf{b}, \quad (1)$$

donde $A = (a_{ij}) \in \mathbb{R}^{n \times n}$, $\mathbf{b} \in \mathbb{R}^n$ y se busca $\mathbf{x} \in \mathbb{R}^n$. Se supone que todos los elementos diagonales son no nulos, $a_{ii} \neq 0$ para $i = 1, \dots, n$. Esta hipótesis no es un capricho técnico: como se verá, en cada paso del método se despeja la incógnita x_i de la i -ésima ecuación y para ello hay que dividir entre a_{ii} . Además, es lo que garantiza que las matrices triangulares que aparecerán más adelante sean invertibles.

Un método iterativo genera una sucesión $\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots$ que, bajo condiciones adecuadas, converge a la solución de (1). La idea común a Jacobi, Gauss–Seidel y SOR es separar la matriz A en una parte fácil de invertir y una parte que se trata de forma explícita. Para ello se descompone

$$A = D - L - U, \quad (2)$$

donde $D = \text{diag}(a_{11}, \dots, a_{nn})$ contiene la diagonal de A , y L y U son las matrices estrictamente triangular inferior y estrictamente triangular superior, respectivamente, definidas por

$$L_{ij} = \begin{cases} -a_{ij}, & i > j, \\ 0, & i \leq j, \end{cases} \quad U_{ij} = \begin{cases} -a_{ij}, & i < j, \\ 0, & i \geq j. \end{cases} \quad (3)$$

El signo negativo en (3) es una convención que se adopta para que en (2) aparezca $D - L - U$ y, como consecuencia, los factores que se obtienen más abajo tengan signos positivos limpios; no cambia nada esencial del método. Conviene señalar que L y U no son los factores de la factorización LU de A : aquí son simplemente las partes inferior y superior de la propia matriz, cambiadas de signo. Si A es simétrica, entonces $U_{ij} = -a_{ij} = -a_{ji} = L_{ji}$, es decir, $U = L^T$, hecho que se usará en la sección de convergencia.

2. El método de Gauss–Seidel como punto de partida

Se escribe la i -ésima ecuación de (1) separando el término diagonal:

$$\sum_{j=1}^n a_{ij}x_j = b_i \iff a_{ii}x_i + \sum_{j<i} a_{ij}x_j + \sum_{j>i} a_{ij}x_j = b_i, \quad (4)$$

y se despeja x_i , lo que es posible porque $a_{ii} \neq 0$:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij}x_j - \sum_{j>i} a_{ij}x_j \right). \quad (5)$$

La solución exacta satisface las n igualdades (5) simultáneamente. Un método iterativo consiste en usar el lado derecho de (5) con valores aproximados para producir un nuevo valor de x_i . El

método de Jacobi emplea en el lado derecho únicamente valores de la iteración anterior $\mathbf{x}^{(k)}$. El método de Gauss–Seidel introduce una mejora natural: cuando se calcula $x_i^{(k+1)}$ ya se conocen las componentes $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ de la iteración nueva, y como se espera que sean mejores aproximaciones que las antiguas, se usan de inmediato. Así,

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)} \right), \quad i = 1, \dots, n. \quad (6)$$

Para pasar a la forma matricial se multiplica (6) por a_{ii} y se pasa al lado izquierdo la suma con $j < i$:

$$a_{ii}x_i^{(k+1)} + \sum_{j<i} a_{ij}x_j^{(k+1)} = b_i - \sum_{j>i} a_{ij}x_j^{(k)}. \quad (7)$$

Ahora se traducen las sumas a productos matriz-vector usando (3). Como $L_{ij} = -a_{ij}$ para $j < i$ y $L_{ij} = 0$ para $j \geq i$, se tiene $\sum_{j<i} a_{ij}x_j = -(\mathbf{L}\mathbf{x})_i$; análogamente $\sum_{j>i} a_{ij}x_j = -(\mathbf{U}\mathbf{x})_i$; y $a_{ii}x_i = (\mathbf{D}\mathbf{x})_i$. La igualdad anterior, escrita para las n componentes a la vez, queda

$$(\mathbf{D} - \mathbf{L})\mathbf{x}^{(k+1)} = \mathbf{U}\mathbf{x}^{(k)} + \mathbf{b}. \quad (8)$$

La matriz $\mathbf{D} - \mathbf{L}$ es triangular inferior con diagonal $a_{11}, \dots, a_{nn}$, no nula, luego es invertible y

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \mathbf{L})^{-1}\mathbf{U}\mathbf{x}^{(k)} + (\mathbf{D} - \mathbf{L})^{-1}\mathbf{b}. \quad (9)$$

Esto también explica por qué (6) se puede evaluar componente a componente: resolver el sistema triangular inferior (8) por sustitución hacia adelante calcula primero $x_1^{(k+1)}$, luego $x_2^{(k+1)}$ usando $x_1^{(k+1)}$, y así sucesivamente, que es exactamente el orden en que se usan los valores nuevos.

Antes de seguir, es útil reescribir (6) de otra forma. Sea

$$\tilde{x}_i^{(k+1)} := \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)} \right) \quad (10)$$

el valor que proporciona Gauss–Seidel para la componente i . Sumando y restando $x_i^{(k)}$ y observando que $-x_i^{(k)} = -\frac{1}{a_{ii}}a_{ii}x_i^{(k)}$, se obtiene

$$\tilde{x}_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j\geq i} a_{ij}x_j^{(k)} \right), \quad (11)$$

pues al añadir el término $j = i$ dentro del paréntesis se resta $a_{ii}x_i^{(k)}$, que al dividir entre a_{ii} compensa exactamente el $+x_i^{(k)}$ agregado fuera. El paréntesis de (11) es el residuo de la i -ésima ecuación evaluado con los valores más recientes disponibles,

$$r_i^{(k)} := b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j\geq i} a_{ij}x_j^{(k)}, \quad (12)$$

de modo que Gauss–Seidel se lee como una corrección de la estimación anterior: $\tilde{x}_i^{(k+1)} = x_i^{(k)} + r_i^{(k)}/a_{ii}$. Esta lectura es la que sugiere el método SOR: si la corrección $r_i^{(k)}/a_{ii}$ apunta en buena dirección, quizá convenga avanzar más (o menos) que la longitud completa de esa corrección.

3. Formulación matricial de SOR

Se introduce un parámetro real $\omega \neq 0$, llamado factor de relajación, y se multiplica el sistema (1) por ω , lo que no altera su solución: $\omega A\mathbf{x} = \omega \mathbf{b}$. Con (2),

$$\omega A = \omega D - \omega L - \omega U. \quad (13)$$

Se suma y se resta D y se reagrupa de modo que en un lado quede una matriz triangular inferior (la que se invertirá) y en el otro el resto:

$$\begin{aligned} \omega A &= D - \omega L - [D - \omega D + \omega U] \\ &= (D - \omega L) - [(1 - \omega)D + \omega U]. \end{aligned} \quad (14)$$

La segunda línea se comprueba desarrollando: $D - \omega L - (1 - \omega)D - \omega U = \omega D - \omega L - \omega U = \omega A$. Sustituyendo (14) en $\omega A\mathbf{x} = \omega \mathbf{b}$ y pasando el corchete al lado derecho, el sistema equivale a

$$(D - \omega L)\mathbf{x} = [(1 - \omega)D + \omega U]\mathbf{x} + \omega \mathbf{b}. \quad (15)$$

Este es un problema de punto fijo. Se convierte en iteración evaluando el lado derecho en la aproximación vieja y el izquierdo en la nueva, igual que se hizo en (8):

$$(D - \omega L)\mathbf{x}^{(k+1)} = [(1 - \omega)D + \omega U]\mathbf{x}^{(k)} + \omega \mathbf{b} \quad (16)$$

La matriz $D - \omega L$ es triangular inferior con diagonal $a_{ii} \neq 0$ (el término ωL tiene diagonal nula), luego su determinante es $\prod_i a_{ii} \neq 0$ y es invertible. Por tanto

$$\mathbf{x}^{(k+1)} = T_\omega \mathbf{x}^{(k)} + \mathbf{c}_\omega, \quad T_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U], \quad \mathbf{c}_\omega = \omega(D - \omega L)^{-1}\mathbf{b}. \quad (17)$$

Si $\mathbf{x}^*$ es un punto fijo de (17), entonces $(D - \omega L)\mathbf{x}^* = [(1 - \omega)D + \omega U]\mathbf{x}^* + \omega \mathbf{b}$, es decir, $[(D - \omega L) - (1 - \omega)D - \omega U]\mathbf{x}^* = \omega \mathbf{b}$, y por (14) esto es $\omega A\mathbf{x}^* = \omega \mathbf{b}$. Como $\omega \neq 0$, se concluye $A\mathbf{x}^* = \mathbf{b}$: la iteración es consistente, esto es, su único punto fijo es la solución del sistema original (único porque $I - T_\omega$ es invertible cuando A lo es, ya que $I - T_\omega = \omega(D - \omega L)^{-1}A$).

También se puede escribir SOR como una descomposición $A = M_\omega - N_\omega$ con

$$M_\omega = \frac{1}{\omega}(D - \omega L) = \frac{1}{\omega}D - L, \quad N_\omega = \frac{1 - \omega}{\omega}D + U. \quad (18)$$

En efecto, $M_\omega - N_\omega = (\frac{1}{\omega} - \frac{1-\omega}{\omega})D - L - U = D - L - U = A$, pues $\frac{1}{\omega} - \frac{1-\omega}{\omega} = 1$. Con esta descomposición, (16) es $M_\omega \mathbf{x}^{(k+1)} = N_\omega \mathbf{x}^{(k)} + \mathbf{b}$ (basta multiplicar (16) por $1/\omega$) y $T_\omega = M_\omega^{-1}N_\omega = I - M_\omega^{-1}A$. Esta última igualdad sale de $N_\omega = M_\omega - A$.

Una tercera forma, que conecta con (11), se obtiene usando $(1 - \omega)D + \omega U = (D - \omega L) - \omega A$, identidad que es (14) despejada. Sustituyendo en (16),

$$(D - \omega L)\mathbf{x}^{(k+1)} = (D - \omega L)\mathbf{x}^{(k)} - \omega A\mathbf{x}^{(k)} + \omega \mathbf{b} \implies \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega(D - \omega L)^{-1}(\mathbf{b} - A\mathbf{x}^{(k)}), \quad (19)$$

donde se ha multiplicado por $(D - \omega L)^{-1}$. Así, SOR es un paso de corrección: se toma el residuo del sistema en la aproximación actual, se “resuelve” de forma aproximada con la matriz triangular $(D - \omega L)/\omega$ y se suma el resultado.

4. Formulación por coordenadas

Se escribe la componente i de (16). El lado izquierdo es

$$[(D - \omega L)\mathbf{x}^{(k+1)}]_i = a_{ii}x_i^{(k+1)} - \omega \sum_{j < i} L_{ij}x_j^{(k+1)} = a_{ii}x_i^{(k+1)} + \omega \sum_{j < i} a_{ij}x_j^{(k+1)}, \quad (20)$$

porque $L_{ij} = -a_{ij}$ para $j < i$ y $L_{ij} = 0$ para $j \geq i$. El lado derecho es

$$[((1 - \omega)D + \omega U)\mathbf{x}^{(k)} + \omega \mathbf{b}]_i = (1 - \omega)a_{ii}x_i^{(k)} - \omega \sum_{j>i} a_{ij}x_j^{(k)} + \omega b_i, \quad (21)$$

porque $U_{ij} = -a_{ij}$ para $j > i$ y $U_{ij} = 0$ para $j \leq i$. Igualando ambos y despejando el término con $x_i^{(k+1)}$:

$$a_{ii}x_i^{(k+1)} = (1 - \omega)a_{ii}x_i^{(k)} + \omega \left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)} \right). \quad (22)$$

Dividiendo entre $a_{ii} \neq 0$ resulta la fórmula de SOR por coordenadas:

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \frac{\omega}{a_{ii}} \left(b_i - \sum_{j<i} a_{ij}x_j^{(k+1)} - \sum_{j>i} a_{ij}x_j^{(k)} \right), \quad i = 1, \dots, n \quad (23)$$

Al igual que en Gauss–Seidel, la triangularidad de $D - \omega L$ significa que el lado derecho de (23) solo involucra componentes nuevas con índice menor que i , que ya han sido calculadas cuando se llega a la componente i . Por eso la fórmula es explícita y puede evaluarse sobreescribiendo x_i en el mismo vector, sin necesidad de guardar dos copias como en Jacobi.

Para comprobar que la fórmula por coordenadas y la forma de corrección (19) coinciden, se usa (10): el paréntesis de (23) dividido entre a_{ii} es exactamente $\tilde{x}_i^{(k+1)}$, de modo que

$$x_i^{(k+1)} = (1 - \omega)x_i^{(k)} + \omega \tilde{x}_i^{(k+1)} = x_i^{(k)} + \omega(\tilde{x}_i^{(k+1)} - x_i^{(k)}) = x_i^{(k)} + \omega \frac{r_i^{(k)}}{a_{ii}}, \quad (24)$$

donde la última igualdad usa (11)–(12). La expresión (24) muestra que $\mathbf{x}^{(k+1)}$ es, componente a componente, un promedio ponderado (o una extrapolación, si $\omega > 1$) entre el valor anterior y el de Gauss–Seidel.

5. Conexión con Gauss–Seidel

Tomando $\omega = 1$ en (23), el factor $(1 - \omega)$ se anula y $\omega/a_{ii} = 1/a_{ii}$, lo que da exactamente (6). En forma matricial, $\omega = 1$ en (16) produce $(D - L)\mathbf{x}^{(k+1)} = U\mathbf{x}^{(k)} + \mathbf{b}$, que es (8); y en (18), $M_1 = D - L$ y $N_1 = U$. Por tanto Gauss–Seidel es el caso particular $\omega = 1$ de SOR, y SOR es una familia uniparamétrica de métodos que contiene a Gauss–Seidel.

La lectura de (24) da el significado del parámetro. Si $0 < \omega < 1$ (subrelajación), el nuevo valor queda entre el anterior y el de Gauss–Seidel, lo que amortigua la corrección; esto puede ayudar a que converja un sistema para el cual Gauss–Seidel oscila o diverge. Si $\omega = 1$, se acepta la corrección completa. Si $1 < \omega < 2$ (sobrerrelajación), se avanza más allá de la corrección de Gauss–Seidel en la misma dirección; cuando Gauss–Seidel converge de forma monótona pero lenta, esa extrapolación acelera la convergencia, y de ahí el nombre del método. La elección de ω se hace, por tanto, para minimizar el radio espectral de T_ω , lo que se justifica en la siguiente sección.

6. Condiciones de convergencia

Sea $\mathbf{x}^*$ la solución de (1) y $\mathbf{e}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^*$ el error. Como $\mathbf{x}^*$ es punto fijo, $\mathbf{x}^* = T_\omega \mathbf{x}^* + \mathbf{c}_\omega$, y restando de (17) se obtiene $\mathbf{e}^{(k+1)} = T_\omega \mathbf{e}^{(k)}$, luego $\mathbf{e}^{(k)} = T_\omega^k \mathbf{e}^{(0)}$. El error tiende a cero para

todo dato inicial si y solo si $T_\omega^k \rightarrow 0$, lo cual, por la forma canónica de Jordan de T_ω , ocurre si y solo si el radio espectral cumple $\rho(T_\omega) < 1$. Este es el criterio general para cualquier método de la forma (17).

Condición necesaria (Kahan). Se calcula el determinante de T_ω . Como $(D - \omega L)^{-1}$ es triangular con diagonal $1/a_{ii}$ y $(1 - \omega)D + \omega U$ es triangular superior con diagonal $(1 - \omega)a_{ii}$,

$$\det T_\omega = \frac{1}{\prod_i a_{ii}} \cdot (1 - \omega)^n \prod_i a_{ii} = (1 - \omega)^n. \quad (25)$$

El determinante es el producto de los valores propios contados con multiplicidad, y cada uno tiene módulo a lo sumo $\rho(T_\omega)$, luego $|1 - \omega|^n = |\det T_\omega| \leq \rho(T_\omega)^n$, es decir, $\rho(T_\omega) \geq |1 - \omega|$. Para que haya convergencia hace falta $\rho(T_\omega) < 1$, y por tanto $|1 - \omega| < 1$, lo que equivale a

$$0 < \omega < 2. \quad (26)$$

Este resultado vale para cualquier matriz con $a_{ii} \neq 0$: fuera de ese intervalo SOR no puede converger para todo dato inicial.

Condición suficiente (Ostrowski–Reich). Si A es simétrica definida positiva y $0 < \omega < 2$, entonces $\rho(T_\omega) < 1$. Para probarlo, sea λ un valor propio (posiblemente complejo) de T_ω con vector propio $\mathbf{v} \neq 0$. Como $T_\omega = I - M_\omega^{-1}A$, la igualdad $T_\omega \mathbf{v} = \lambda \mathbf{v}$ da $M_\omega^{-1}A\mathbf{v} = (1 - \lambda)\mathbf{v}$, es decir,

$$A\mathbf{v} = (1 - \lambda)M_\omega \mathbf{v}. \quad (27)$$

Se tiene $\lambda \neq 1$, pues de lo contrario $A\mathbf{v} = 0$ con $\mathbf{v} \neq 0$, lo que contradice que A sea definida positiva. Multiplicando (27) por $\mathbf{v}^*$ (transpuesta conjugada) y despejando,

$$\mathbf{v}^* M_\omega \mathbf{v} = \frac{\mathbf{v}^* A \mathbf{v}}{1 - \lambda}, \quad \mathbf{v}^* M_\omega^T \mathbf{v} = \overline{\mathbf{v}^* M_\omega \mathbf{v}} = \frac{\mathbf{v}^* A \mathbf{v}}{1 - \bar{\lambda}}, \quad (28)$$

donde la segunda igualdad usa que $\mathbf{v}^* A \mathbf{v}$ es real (por ser A simétrica real) y que M_ω es real. Sumando,

$$\mathbf{v}^* (M_\omega + M_\omega^T) \mathbf{v} = \mathbf{v}^* A \mathbf{v} \left(\frac{1}{1 - \lambda} + \frac{1}{1 - \bar{\lambda}} \right) = \mathbf{v}^* A \mathbf{v} \frac{2 - 2 \operatorname{Re} \lambda}{|1 - \lambda|^2}. \quad (29)$$

Como $|1 - \lambda|^2 = 1 - 2 \operatorname{Re} \lambda + |\lambda|^2$, se cumple $2 - 2 \operatorname{Re} \lambda = |1 - \lambda|^2 + 1 - |\lambda|^2$, y entonces

$$\mathbf{v}^* (M_\omega + M_\omega^T) \mathbf{v} = \mathbf{v}^* A \mathbf{v} \left(1 + \frac{1 - |\lambda|^2}{|1 - \lambda|^2} \right). \quad (30)$$

Por otro lado, por la simetría de A se tiene $U = L^T$, luego $L + L^T = L + U = D - A$, y de (18),

$$M_\omega + M_\omega^T = \frac{2}{\omega} D - (L + L^T) = \frac{2}{\omega} D - D + A = A + \left(\frac{2}{\omega} - 1 \right) D. \quad (31)$$

Sustituyendo esto en el lado izquierdo de (30) y cancelando $\mathbf{v}^* A \mathbf{v}$ a ambos lados,

$$\mathbf{v}^* A \mathbf{v} \frac{1 - |\lambda|^2}{|1 - \lambda|^2} = \left(\frac{2}{\omega} - 1 \right) \mathbf{v}^* D \mathbf{v}. \quad (32)$$

Como A es definida positiva, sus elementos diagonales son positivos, luego D es definida positiva y $\mathbf{v}^* D \mathbf{v} > 0$; además $\frac{2}{\omega} - 1 > 0$ si y solo si $0 < \omega < 2$. El lado derecho es entonces positivo, y como $\mathbf{v}^* A \mathbf{v} > 0$ y $|1 - \lambda|^2 > 0$, debe ser $1 - |\lambda|^2 > 0$, es decir, $|\lambda| < 1$. Al valer esto para todo valor propio, $\rho(T_\omega) < 1$. En particular, con $\omega = 1$ se recupera el conocido resultado de que Gauss–Seidel converge para matrices simétricas definidas positivas.

Los dos resultados anteriores acotan el intervalo útil de ω pero no dicen cuál valor es el mejor. Para una clase de matrices con cierta estructura de bloques (matrices “consistentemente ordenadas”,

como las que provienen de discretizar la ecuación de Poisson con diferencias finitas), Young demostró que los valores propios de T_ω se relacionan con los de la matriz de Jacobi μ mediante $(\lambda + \omega - 1)^2 = \lambda \omega^2 \mu^2$, y de ahí que el valor óptimo, cuando los μ son reales, sea $\omega_{\text{opt}} = 2 / (1 + \sqrt{1 - \rho(T_{\text{Jacobi}})^2})$. Ese resultado se enuncia aquí sin demostración, pues requiere el desarrollo específico de las matrices consistentemente ordenadas, que excede el objetivo de esta deducción.